


Dept. de Ciència de la Computació i Intel·ligència Artificial
Dpto. de Ciencia de la Computación e Inteligencia Artificial




Universitat d'Alacant
Universidad de Alicante

Sistemas Inteligentes


TEMA 5: Árboles de Decisión y
Redes Bayesianas

TEMA 5: Árboles de Decisión y Redes Bayesianas1

1



Dept. de Ciència de la Computació i Intel·ligència Artificial
Dpto. de Ciencia de la Computación e Inteligencia Artificial



Universitat d'Alacant
Universidad de Alicante

Sistemas Inteligentes

Parte 1: Árboles de decisión

- Árboles de decisión
 - Planteamiento del problema
 - Ejemplo: Concesión de créditos
 - Entropía y Ganancia de Información
- Algoritmo ID3
 - Algoritmo recursivo
 - Aplicación al ejemplo
 - Consideración de atributos numéricos
 - Atributos con un gran número de valores

TEMA 5: Árboles de Decisión y Redes Bayesianas2

2

Dept. de Ciència de la Computació i Intel·ligència Artificial
 Dpto. de Ciencia de la Computación e Inteligencia Artificial
 Universitat d'Alacant
 Universidad de Alicante

Sistemas Inteligentes

Árboles de decisión

■ **Características:**

- Estructura para **clasificación** de vectores de atributos.
- Establece **en qué orden** testar los atributos para conseguir la clasificación del vector de entrada.
- Para componer dicho orden se eligen primero aquellos atributos que **mejor ganancia de información** prometen a efectos de descubrir la clase del vector de entrada.
- Es interesante **aprenderlos** a partir de un conjunto de vectores

```

graph TD
    Moroso((Moroso)) -- Si --> N1[No conceder]
    Moroso -- No --> Ingresos((Ingresos  
(Eur./mes)))
    Ingresos -- "<600" --> N2[No conceder]
    Ingresos -- "600-1200" --> Trabajo((Trabajo fijo))
    Ingresos -- ">1200" --> N3[Conceder]
    Trabajo -- Si --> N4[Conceder]
    Trabajo -- No --> N5[No conceder]
      
```

TEMA 5: Árboles de Decisión y Redes Bayesianas

3

3

Dept. de Ciència de la Computació i Intel·ligència Artificial
 Dpto. de Ciencia de la Computación e Inteligencia Artificial
 Universitat d'Alacant
 Universidad de Alicante

Sistemas Inteligentes

Ejemplo “Concesión de créditos”

| Cliente | Moroso | Antigüedad (años) | Ingresos (Eur./mes) | Trab.fijo | Conceder |
|---------|-----------|-------------------|---------------------|-----------|----------|
| 1 | sí | >5 | 600-1200 | sí | no |
| 2 | no | <1 | 600-1200 | sí | sí |
| 3 | sí | 1-5 | >1200 | sí | no |
| 4 | no | >5 | >1200 | no | sí |
| 5 | no | <1 | >1200 | sí | sí |
| 6 | sí | 1-5 | 600-1200 | sí | no |
| 7 | no | 1-5 | >1200 | sí | sí |
| 8 | no | <1 | <600 | sí | no |
| 9 | no | >5 | 600-1200 | no | no |
| 10 | sí | 1-5 | <600 | no | no |

■ **Aprendizaje:**

- ¿Por qué atributo **comenzar** primero?
- Esquema voraz: Elegir uno y **filtrar recursivamente**.

TEMA 5: Árboles de Decisión y Redes Bayesianas

4

4

Departament de Ciència de la Computació i Intel·ligència Artificial
 Departament de Ciència de la Computació i Intel·ligència Artificial
 Universitat d'Alacant
 Universitat de Alicante

Sistemas Inteligentes

Entropía

■ **Definición:**

- Medida del **grado de incertidumbre** asociado a una distribución de probabilidad.
- En una **distribución uniforme**, todos los valores son igualmente probables $P_i = 1/N$ y por tanto la **entropía es máxima**, lo cual indica máxima incertidumbre.
- Por el contrario, en una **distribución pico** en la que $P_i = 1$ y $P_j = 0$, para todo $j \neq i$ la entropía es mínima lo cual indica mínima incertidumbre o sea **máxima información**.

$$E(S) = \sum_{i \in C} -p_i \log_2 p_i$$

si no

$$-0.51 \log_2(0.5) - 0.51 \log_2(0.5) = 1$$

si

$$-1.01 \log_2(1.0) - 0.01 \log_2(0.0) = 0$$

TEMA 5: Árboles de Decisión y Redes Bayesianas

5

5

Departament de Ciència de la Computació i Intel·ligència Artificial
 Departament de Ciència de la Computació i Intel·ligència Artificial
 Universitat d'Alacant
 Universitat de Alicante

Sistemas Inteligentes

Entropía condicionada

■ **Definición:**

- Entropía de la distribución de Y **condicionada** a X.
- Una entropía condicionada **menor** que $E(Y)$ indica que el conocimiento de X **mejora la información** que se dispone sobre Y

$$E(Y | X) = \sum_j \text{Prob}(X = v_j) E(Y | X = v_j)$$

| v_j | $\text{Prob}(X = v_j)$ | $E(Y X = v_j)$ |
|---------|------------------------|------------------|
| Math | 0.5 | 1 |
| History | 0.25 | 0 |
| CS | 0.25 | 0 |

| X | Y |
|-------|-----|
| Math | Yes |
| Hist. | No |
| CS | Yes |
| Math | No |
| Math | No |
| CS | Yes |
| Hist. | No |
| Math | Yes |

$E(Y) = 1$
 $E(Y|X) = 0.5 * 1 + 0.25 * 0 + 0.25 * 0$

$E(Y|X) = 0.5$

TEMA 5: Árboles de Decisión y Redes Bayesianas

6

6

Ganancia de información

Definición:

- Medida de **cuanto ayuda el conocer** el valor de una variable aleatoria X para conocer el verdadero valor de otra Y .
- En nuestro caso, X es un **atributo** de un ejemplo dado mientras que Y es la **clase** a la que pertenece el ejemplo.
- Una alta ganancia implica que el atributo X permite **reducir la incertidumbre de la clasificación** del ejemplo de entrada.

$$IG(Y | X) = E(Y) - E(Y | X)$$

| X | Y |
|---------|-----|
| Math | Yes |
| History | No |
| CS | Yes |
| Math | No |
| Math | No |
| CS | Yes |
| History | No |
| Math | Yes |

$$E(Y) = 1$$

$$E(Y|X) = 0.5$$

$$IG(Y | X) = 1 - 0.5 = 0.5$$

Algoritmo recursivo

```

Algoritmo ID3(ejemplos, atributos) {
  Si atributos = ∅ o MISMACLASE(ejemplos) {
     $C \leftarrow$  CLASEMAYORITARIA(ejemplos)
     $N \leftarrow$  CREAMODOHOJA( $C$ )
  }
  Sino {
     $a_{max} \leftarrow \max_{A \in \text{atributos}} G(\text{ejemplos}, A)$ 
     $N \leftarrow$  CREAMODO( $a_{max}$ )
    Para cada  $v_i \in \text{VALORES}(a_{max})$  {
       $\text{ejemplos}_{v_i} \leftarrow \{\text{elementos de ejemplos con valor } v_i \text{ para } a_{max}\}$ 
      AÑADIRHIJO( $N$ , ID3( $\text{ejemplos}_{v_i}$ , atributos -  $a_{max}$ ))
    }
  }
  Devolver  $N$ 
}

```


Extensiones del algoritmo

Extensiones:

- **Atributos numéricos:** ID3 sólo trabaja con atributos discretos. Si se usan **atributos continuos** hay que **descomponerlos en rangos**. Para ello se ordenan los ejemplos según el valor y se toman como puntos límite los puntos medios de aquellos en que se cambie de clase.

| | | | | 825 | 950 | 1150 | | | | | | |
|----------|-----|-----|-----|-----|-----|------|------|------|------|------|--|--|
| Ejemplo | 8 | 10 | 6 | 2 | 1 | 9 | 3 | 5 | 4 | 7 | | |
| Ingresos | 450 | 530 | 650 | 800 | 850 | 1050 | 1250 | 1400 | 1600 | 3000 | | |
| Crédito | no | no | no | no | sí | no | sí | sí | sí | sí | | |

- **Atributos con gran número de valores.** Se forman grupos pequeños de ejemplos que pueden ser **homogéneos por casualidad**. Debe introducirse un elemento corrector que penalice atributos con un **elevado número de valores (ganancia normalizada)**:

$$G_N(S, A) = \frac{G(S, A)}{\sum_{v_i \in V(A)} -p_{v_i} \log_2 p_{v_i}}$$

- **Sobre-entrenamiento.** Comprobación de capacidad de generalización

Ejercicios

Objetivo: Dado el conjunto de entrenamiento, aprender el concepto “Días en los que se juega al tenis” obteniendo el árbol de decisión mediante el algoritmo ID3

| EJ. | CIELO | TEMPERATURA | HUMEDAD | VIENTO | JUGAR TENIS |
|-----------------|---------|-------------|---------|--------|-------------|
| D ₁ | SOLEADO | ALTA | ALTA | DÉBIL | - |
| D ₂ | SOLEADO | ALTA | ALTA | FUERTE | - |
| D ₃ | NUBLADO | ALTA | ALTA | DÉBIL | + |
| D ₄ | LLUVIA | SUAVE | ALTA | DÉBIL | + |
| D ₅ | LLUVIA | BAJA | NORMAL | DÉBIL | + |
| D ₆ | LLUVIA | BAJA | NORMAL | FUERTE | - |
| D ₇ | NUBLADO | BAJA | NORMAL | FUERTE | + |
| D ₈ | SOLEADO | SUAVE | ALTA | DÉBIL | - |
| D ₉ | SOLEADO | BAJA | NORMAL | DÉBIL | + |
| D ₁₀ | LLUVIA | SUAVE | NORMAL | DÉBIL | + |
| D ₁₁ | SOLEADO | SUAVE | NORMAL | FUERTE | + |
| D ₁₂ | NUBLADO | SUAVE | ALTA | FUERTE | + |
| D ₁₃ | NUBLADO | ALTA | NORMAL | DÉBIL | + |
| D ₁₄ | LLUVIA | SUAVE | ALTA | FUERTE | - |

Sistemas Inteligentes

Ejercicios

HUMEDAD

```

graph TD
    H[HUMEDAD] -- ALTA --> A["[3+, 4-]"]
    H -- NORMAL --> N["[6+, 1-]"]
        
```

VIENTO

```

graph TD
    V[VIENTO] -- Débil --> D["[6+, 2-]"]
    V -- Fuerte --> F["[3+, 3-]"]
        
```

CIELO

```

graph TD
    C[CIELO] -- SOLEADO --> S["[2+, 3-]"]
    C -- NUBLADO --> N["[4+, 0-]"]
    C -- LLUVIA --> L["[3+, 2-]"]
        
```

TEMPERATURA

```

graph TD
    T[TEMPERATURA] -- ALTA --> A["[2+, 2-]"]
    T -- SUAVE --> S["[4+, 2-]"]
    T -- BAJA --> B["[3+, 1-]"]
        
```

TEMA 5: Árboles de Decisión y Redes Bayesianas

13

13

Sistemas Inteligentes

Ejercicios

- Entropía inicial: $\text{Ent}([9^+, 5^-]) = 0,94$
- Selección del atributo para el nodo raíz:
 - $\text{Ganancia}(D, \text{HUMEDAD}) = 0,94 - \frac{7}{14} \cdot \text{Ent}([3^+, 4^-]) - \frac{7}{14} \cdot \text{Ent}([6^+, 1^-]) = 0,151$
 - $\text{Ganancia}(D, \text{VIENTO}) = 0,94 - \frac{8}{14} \cdot \text{Ent}([6^+, 2^-]) - \frac{6}{14} \cdot \text{Ent}([3^+, 3^-]) = 0,048$
 - $\text{Ganancia}(D, \text{CIELO}) = 0,94 - \frac{5}{14} \cdot \text{Ent}([2^+, 3^-]) - \frac{4}{14} \cdot \text{Ent}([4^+, 0^-]) - \frac{5}{14} \cdot \text{Ent}([3^+, 2^-]) = 0,246$ (mejor atributo)
 - $\text{Ganancia}(D, \text{TEMPERATURA}) = 0,94 - \frac{4}{14} \cdot \text{Ent}([2^+, 2^-]) - \frac{6}{14} \cdot \text{Ent}([4^+, 2^-]) - \frac{4}{14} \cdot \text{Ent}([3^+, 1^-]) = 0,02$
- El atributo seleccionado es CIELO


TEMA 5: Árboles de Decisión y Redes Bayesianas

14

14

Ejercicios

Árbol parcialmente construido:



Ejercicios

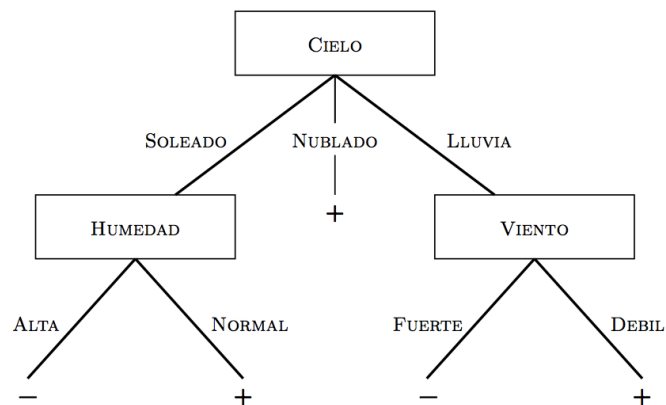
- Selección del atributo para el nodo CIELO=SOLEADO
- $D_{\text{SOLEADO}} = \{D_1, D_2, D_8, D_9, D_{11}\}$ con entropía $\text{Ent}([2^+, 3^-]) = 0,971$
 - $\text{Ganancia}(D_{\text{SOLEADO}}, \text{HUMEDAD}) = 0,971 - \frac{3}{5} \cdot 0 - \frac{2}{5} \cdot 0 = 0,971$ (mejor atributo)
 - $\text{Ganancia}(D_{\text{SOLEADO}}, \text{TEMPERATURA}) = 0,971 - \frac{2}{5} \cdot 0 - \frac{2}{5} \cdot 1 - \frac{1}{5} \cdot 0 = 0,570$
 - $\text{Ganancia}(D_{\text{SOLEADO}}, \text{VIENTO}) = 0,971 - \frac{2}{5} \cdot 1 - \frac{3}{5} \cdot 0,918 = 0,019$
- El atributo seleccionado es HUMEDAD

Ejercicios

- Selección del atributo para el nodo CIELO=LLUVIA:
- $D_{LLUVIA} = \{D_4, D_5, D_6, D_{10}, D_{14}\}$ con entropía $Ent([3^+, 2^-]) = 0,971$
 - $Ganancia(D_{LLUVIA}, HUMEDAD) = 0,971 - \frac{2}{5} \cdot 1 - \frac{3}{5} \cdot 0,918 = 0,820$
 - $Ganancia(D_{LLUVIA}, TEMPERATURA) = 0,971 - \frac{3}{5} \cdot 0,918 - \frac{2}{5} \cdot 1 = 0,820$
 - $Ganancia(D_{LLUVIA}, VIENTO) = 0,971 - \frac{3}{5} \cdot 0 - \frac{2}{5} \cdot 0 = 0,971$ (mejor atributo)
- El atributo seleccionado es VIENTO

Ejercicios

- Árbol finalmente aprendido:



Parte 2: Redes Bayesianas

Probabilidad como medida de incertidumbre

Teorema de Bayes

Redes Bayesianas

Inferencia mediante redes Bayesianas

- Inferencia Exacta
- Ejemplos
- Inferencia aproximada
 - Muestreo directo
 - Muestreo por rechazo
 - Muestreo Gibbs

Para saber más

19

Teorema de Bayes

Sabemos que:

$$\frac{P(A|B) P(B)}{P(B|A) P(A)} = \frac{P(A,B)}{P(B,A)} = P(A,B)$$

Regla de Bayes

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} = \alpha \cdot P(B|A)P(A)$$

Constante de normalización $P(B)$

$$P(B) = \sum_i P(B|A_i)P(A_i)$$

Regla de la cadena

$$P(A, B) = P(A)P(B|A)$$

$$P(A, B, C) = P(A)P(B|A)P(C|B, A)$$

20

Redes Bayesianas (I)

Una red bayesiana es:

- Un grafo acíclico dirigido para representar dependencias entre variables y mostrar una descripción escueta de cualquier distribución de probabilidad conjunta completa

Esta formada por

- Un conjunto de variables aleatorias que forman los nodos de la red. Cada nodo X tendrá adjunta una distribución $P(X|\text{Padres}(X))$
- Un conjunto de enlaces que determinan la influencia (dependencia) entre nodos. Si X se conecta con Y se dice que X influye a Y


Su finalidad principal es calcular la distribución conjunta de las variables nodo

21

Redes Bayesianas (II) Semántica

Dada la siguiente red bayesiana,


¿Qué distribución representa



Redes Bayesianas (III)

Semántica

- $P(T, R, A, J, M) =$



$$P(T) \cdot P(R) \cdot P(A|T, R) \cdot P(J|A) \cdot P(M|A)$$


- ¿ $|P(T, R, A, J, M)|$ sin independencia condicional?
 - $2^5 = 32$
- ¿Y con independencia condicional?
 - $2 + 2 + 2^3 + 2^2 + 2^2 = 20$

23

Redes Bayesianas (IV)

Semántica

- Cobertura de Markov
 - Un nodo A es condicionalmente independiente de todos los nodos de la red dados:
 - Sus padres
 - Sus hijos
 - Los padres de sus hijos



24

Sistemas Inteligentes

Dept. de Ciència de la Computació i Intel·ligència Artificial
 Dpto. de Ciencia de la Computación e Inteligencia Artificial
 Universitat d'Alacant
 Universidad de Alicante

Inferencia

¿Para que queremos la distribución conjunta?

A partir de la distribución conjunta podemos contestar cualquier pregunta relativa a la red...

Varios tipos de inferencia en redes Bayesianas

- Exacta (caso general)
- Casos especiales (Kim&Pearl...)
- Aproximada

25

TEMA 5: Árboles de Decisión y Redes Bayesianas

25

Sistemas Inteligentes

Dept. de Ciència de la Computació i Intel·ligència Artificial
 Dpto. de Ciencia de la Computación e Inteligencia Artificial
 Universitat d'Alacant
 Universidad de Alicante

Inferencia exacta (I)

Inferencia exacta general (funciona para todas la RR.BB.)

Regla de inferencia general

(Donde B son las variables buscadas, C las conocidas y D las desconocidas)

$$P(B | C) = \alpha \cdot \sum_D P(B, D, C)$$

Problema: Mucha complejidad

26

TEMA 5: Árboles de Decisión y Redes Bayesianas

26


Inferencia exacta(II)

Ejemplo 1

- ¿Cuál es la probabilidad de que suene la alarma si llama Maria?

$$P(B | C) = \alpha \cdot \sum_D P(B, D, C)$$

$$\begin{aligned} P(R, T, A, J, M) &= \\ &= P(R) \cdot P(T) \cdot P(A | R, T) \cdot P(J | A) \cdot P(M | A) \end{aligned}$$



27

Inferencia (III)

Ejemplo 1

De esta manera tenemos que:

$$\begin{aligned} P(A | M) &= \alpha \cdot \sum_R \sum_T \sum_J P(R, T, A, J, M) = \\ &= \alpha \cdot \sum_R \sum_T \sum_J P(R) \cdot P(T) \cdot P(A | R, T) \cdot P(J | A) \cdot P(M | A) = \\ &= \alpha \cdot P(M | A) \cdot \sum_R \left(P(R) \sum_T \left(P(T) \cdot P(A | R, T) \cdot \underbrace{\sum_J P(J | A)}_1 \right) \right) \end{aligned}$$

28

Inferencia (IV)

Ejemplo 2

¿ $P(R|J+,M+)$? Si sabemos que:

$$P(T) = 0,001$$

$$P(R) = 0,002$$

$$P(J|A) =$$


| A | J |
|---|------|
| 0 | 0,05 |
| 1 | 0,9 |

$$P(A|T,R) =$$

| T | R | A |
|---|---|-------|
| 0 | 0 | 0,001 |
| 0 | 1 | 0,94 |
| 1 | 0 | 0,29 |
| 1 | 1 | 0,95 |

$$P(M|A) =$$

| A | M |
|---|------|
| 0 | 0,01 |
| 1 | 0,7 |



29

Inferencia (V)

Ejemplo 2

De esta manera tenemos que:

$$\begin{aligned}
 P(R|J,M) &= \alpha \sum_T \sum_A P(R,T,A,J,M) = \\
 &= \alpha \sum_T \sum_A P(R) \cdot P(T) \cdot P(A|R,T) \cdot P(J|A) \cdot P(M|A) = \\
 &= \alpha \cdot P(R) \cdot \sum_T \left(P(T) \cdot \sum_A (P(A|R,T) \cdot P(J|A) \cdot P(M|A)) \right)
 \end{aligned}$$

30

Dept. de Ciència de la Computació i Intel·ligència Artificial
 Dpto. de Ciencia de la Computación e Inteligencia Artificial
 Universitat d'Alacant
 Universidad de Alicante

Sistemas Inteligentes

Inferencia (VI)

Ejemplo 2

Para calcular descomponemos utilizando un árbol:

$$\alpha \cdot P(R) \cdot \sum_T P(T) \cdot \sum_A P(A | R, T) \cdot P(J | A) \cdot P(M | A)$$

31

TEMA 5: Árboles de Decisión y Redes Bayesianas

31

Dept. de Ciència de la Computació i Intel·ligència Artificial
 Dpto. de Ciencia de la Computación e Inteligencia Artificial
 Universitat d'Alacant
 Universidad de Alicante

Sistemas Inteligentes

Inferencia (VII)

Ejemplo 2

| P(R J,M) | | P(¬R J,M) | |
|----------------------------|-------------------|-----------------------------|-------------------|
| 1 P(A R,T)*P(J A)*P(M A) | 0,5985 | 1 P(A ¬R,T)*P(J A)*P(M A) | 0,1827 |
| P(¬A R,T)*P(J,¬A)*P(M ¬A) | 0,000025 | P(¬A ¬R,T)*P(J,¬A)*P(M ¬A) | 0,000355 |
| P(T) * SUM 1 | 0,00059853 | P(T) * SUM 1 | 0,00018306 |
| 2 P(A R,¬T)*P(J A)*P(M A) | 0,5922 | 2 P(A ¬R,¬T)*P(J A)*P(M A) | 0,00063 |
| P(¬A R,¬T)*P(J,¬A)*P(M ¬A) | 0,00003 | P(¬A ¬R,¬T)*P(J,¬A)*P(M ¬A) | 0,0004995 |
| P(¬T) * SUM 2 | 0,59163777 | P(¬T) * SUM 2 | 0,00112856 |
| TOTAL R+ | 0,00118447 | TOTAL ¬R | 0,00130899 |

Cómo alpha*(R,¬R) = 1

P(R|J,M)= R 0,47503178
 ¬R 0,52496822

32

TEMA 5: Árboles de Decisión y Redes Bayesianas

32

Inferencia (VIII)

Ejercicio 1

¿ $P(J|R)$?

$$\begin{aligned}
 P(J|R) &= \sum_T \sum_A \sum_M P(R) \cdot P(T) \cdot P(A|R, T) \cdot P(J|A) \cdot P(M|A) = \\
 &= P(R) \cdot \sum_T (P(T) \cdot \sum_A (P(A|R, T) \cdot P(J|A) \cdot \sum_M P(M|A)))
 \end{aligned}$$


33

Inferencia exacta en poliárboles

Existen algoritmos más eficientes para tipos específicos de redes

Modelo de Kim y Pearl

- Método de inferencia para redes bayesianas.
- Solo aplicable a un poliárbol.
 - No existe más de un camino entre cada pareja de nodos
- Se basa en el paso de dos tipos de mensajes entre nodos
 - Para actualizar la credibilidad
 - Para introducir nueva evidencia
- Se puede calcular en tiempo lineal



34

Sistemas Inteligentes

Inferencia aproximada (I)

Sobre la inferencia exacta

- Redes con conexión múltiple son intratables utilizando inferencia exacta
- Complejidad NP-hard en el caso general

Inferencia utilizando algoritmos de muestreo aleatorio (Monte Carlo)

- Existen varios algoritmos
 - Muestreo directo
 - Muestreo por rechazo

35

TEMA 5: Árboles de Decisión y Redes Bayesianas

35

Sistemas Inteligentes

Inferencia aproximada (II)

Muestreo directo

- rb : red Bayesiana
- ALGORITMO **Muestreo_Directo**(rb) retorna un evento extraído de rb
 - $X = \langle \text{vector de sucesos con } n \text{ elementos} \rangle$
 - Para cada variable X_i en X_1, \dots, X_n hacer
 - $X_i = \text{Obtener una muestra aleatoria de } P(X_i | \text{Padres}(X_i))$
 - Devolver X

Para responder cualquier pregunta de la red

- Obtener un vector de eventos $X[]$
- Contar apariciones en $X[]$ de las evidencias
- Dividir por suficientesMuestras

36

TEMA 5: Árboles de Decisión y Redes Bayesianas

36

Dept. de Ciència de la Computació i Intel·ligència Artificial
 Dpto. de Ciencia de la Computación e Inteligencia Artificial
 Universitat d'Alacant
 Universidad de Alicante

Inferencia aproximada (III)

Ejemplo de muestreo de una red mediante muestreo directo

Sistemas Inteligentes

$P(T) = 0,001; P(R) = 0,002$

$P(A|T,R)=$

| T | R | A |
|---|---|-------|
| 0 | 0 | 0,001 |
| 0 | 1 | 0,29 |
| 1 | 0 | 0,94 |
| 1 | 1 | 0,95 |

$P(J|A) =$

| A | J |
|---|------|
| 0 | 0,05 |
| 1 | 0,9 |

$P(M|A)=$

| A | J |
|---|------|
| 0 | 0,01 |
| 1 | 0,7 |

1. Muestreo a partir de $P(\text{Terremoto}) = \langle 0,001 \ 0,999 \rangle$.
supongamos (s.) que devuelve *falso*
2. Muestreo($P(\text{Robo})$) s. devuelve *falso*
3. Muestreo($P(\text{Alarma} | \text{Robo=falso}, \text{Terremoto=falso})$)
 s. devuelve *cierto*
4. Muestreo($P(\text{Juan} | A=\text{cierto})$)
 s. Devuelve *cierto*
5. Muestreo($P(\text{Maria} | A=\text{cierto})$)
 s. Devuelve *falso*
6. $X = \langle \text{falso}, \text{falso}, \text{cierto}, \text{cierto}, \text{falso} \rangle$

37

Dept. de Ciència de la Computació i Intel·ligència Artificial
 Dpto. de Ciencia de la Computación e Inteligencia Artificial
 Universitat d'Alacant
 Universidad de Alicante

Inferencia aproximada (IV)

Ejemplo de uso

Sistemas Inteligentes

$\text{¿}P(R|J,M)\text{?}$

$P(T) = 0,001;$
 $P(R) = 0,00$

$P(A|T,R)=$

| T | R | A |
|---|---|-------|
| 0 | 0 | 0,001 |
| 0 | 1 | 0,29 |
| 1 | 0 | 0,94 |
| 1 | 1 | 0,95 |

$P(J|A) =$

| A | J |
|---|------|
| 0 | 0,05 |
| 1 | 0,9 |

$P(M|A)=$

| A | J |
|---|------|
| 0 | 0,01 |
| 1 | 0,7 |

1. Para obtener $P(R|J,M)$
2. $C = \text{Contar } X[]$ que cumpla este patrón
 $X = \langle ?, \text{cierto}, ?, \text{cierto}, \text{cierto} \rangle$
3. Devolver $C/\text{numeroDeMuestras}$

38

Inferencia aproximada (V)

¿Problema del muestreo directo?

Otros tipos de muestreo aleatorio

- Muestreo por rechazo
- Gibbs Sampling

39

Inferencia aproximada (VI)

Muestreo por rechazo

• ALGORITMO **Muestreo_por_Rechazo**(B, c, rb) retorna estimación $P(B|c)$

• Para $j = 1$ hasta num_muestras hacer

- $x = \text{Muestro_Directo}(rb)$
- Si x es consistente con la evidencia c :
- $N[y] = N[y] + 1$, donde y es el valor de B en x

• Devolver $\text{Normalizar}(N)$

Entradas:

- B : variable buscada (pregunta)
- c : valores observados de las variables conocidas C
- rb : red bayesiana

Variables locales:


- N : vector de recuento para cada valor de B , inicialmente 0

40

Inferencia aproximada (VII)

Muestreo por rechazo

Ejemplo:



Queremos estimar $P(\text{Lluvia}|\text{Aspersor}=\text{cierto})$
 Extraemos 100 muestras, de las cuales 73 tienen el aspersor apagado
 Nos quedamos con las 27 que coinciden con la evidencia
 De las 27:

- En 8 Lluvia = cierto
- En 19 Lluvia es falso

$$P(\text{Lluvia}|\text{Aspersor}=\text{cierto}) = \text{Normalizar}(<8,19>) = <0.296, 0.704>$$

41

Bibliografía

- Escolano et al. [Inteligencia Artificial](#). Thomson-Paraninfo 2003. Capítulo 4.
- Mitchel, [Machine Learning](#). McGraw Hill, Computer Science Series. 1997
- Cover, Thomas, [Information Theory](#). Wiley & Sons, New York 1991

42